

HW1 Report

NQ6124052 鄭守維

操作手冊

如何執行專案進行推論

1. 開啟終端機，進入到本專案的 root directory，然後執行以下指令來建置 Docker image
\$ docker build -t <image-name> .
2. 建置完成後，執行以下指令來啟動一個根據 <image-name> 這個 Docker image 生成的 container 並運行本專案
\$ docker run -it <image-name>
3. 運行本專案時，container 會執行本專案中的 start.sh，其會執行本專案中的 Total_result.py，該檔案會進行回測(Backtesting)，最後在終端機畫面中以價格狀況(最高價、最低價、開盤價、收盤價)分類，分別顯示預測日期的實際價格、Transformer-based model 預測價格、Mamba-based model 預測價格、Transformer-based model RMSE 和 Mamba-based model RMSE。如以下圖片所示：

```
#####
TSMC 2024/2/23 High Price Prediction: 695.0
Transformer Predicted High Price: 617.2648
Mamba Predicted High Price: 627.3464
Transformer RMSE: 77.7352294921875
Mamba RMSE: 67.65362548828125
#####
TSMC 2024/2/23 Low Price Prediction: 685.0
Transformer Predicted Low Price: 610.638
Mamba Predicted Low Price: 612.9253
Transformer RMSE: 74.36199951171875
Mamba RMSE: 72.07470703125
#####
TSMC 2024/2/23 Open Price Prediction: 695.0
Transformer Predicted Open Price: 621.1307
Mamba Predicted Open Price: 629.1644
Transformer RMSE: 73.86932373046875
Mamba RMSE: 65.8355712890625
#####
TSMC 2024/2/23 Close Price Prediction: 692.0
Transformer Predicted Close Price: 607.20044
Mamba Predicted Close Price: 624.4637
Transformer RMSE: 84.799560546875
Mamba RMSE: 67.53631591796875
#####
```

作業細節報告

模型運行模式說明


因為我在建構模型及進行測試時發現將資料集裡面一天的價格資料設定為包含作業要求的四項價格種類(也就是讓 sequence data 中的每個 token 的 dimension 為 4)，讓模型在最後一步接上四個 Dense layer 一次預測出四個價格種類，或是讓模型訓練出四個不同的權重分別預測四個價格種類，表現都會比將資料集裡一天的價格資料設定為只有一種，然後讓模型預測該價格種類來的差。所以我在模型訓練的階段建構了四份資料集，分別用來訓練預測四項價格種類的預測模型權重，因此 Transformer-based model 會有四個權重檔案，Mamba-based model 也會有四個權重檔案。

任務一&二 - 模型推論截圖

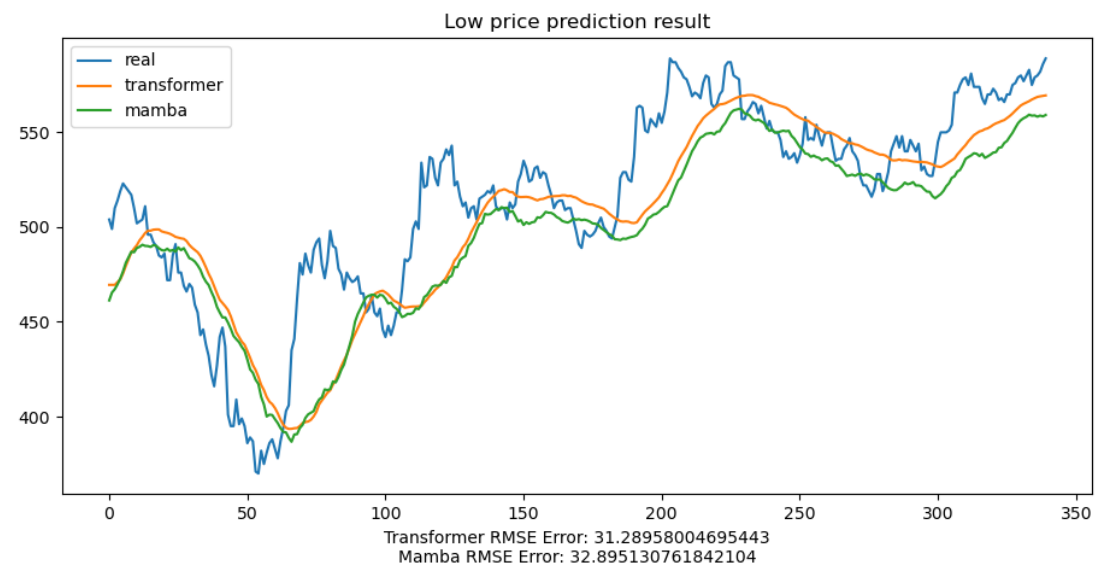
為了方便比較模型表現及效能，我將 Transformer-based model 和 Mam-based model 對測試集的推論表現依照價格種類分類畫在同一張圖表上。

圖表中的 X 軸代表的是時間走向，Y 軸代表的是價格。所以透過圖表，可以從模型預測價格漲跌幅和實際價格的貼合程度來直覺的觀察模型預測表現。而圖表下方也有列出兩個模型分別的 RMSE 來給出實際的誤差數據。


最高價：




最低價：



開盤價：



收盤價：



結論：

除了最低價預測 Mamba-based model 的誤差值略高於 Transformer-based model，整體而言 Mamba-based model 的預測還是較佳。

任務二 - 模型優化說明

首先附上 Transformer-based model 和 Mamba-based model 的模型架構圖

Transformer:

Layer (type)	Output shape	Param #	Connected to
input_layer (InputLayer)	(None, 30, 1)	0	-
time2_vector (Time2Vector)	(None, 30, 2)	120	input_layer[0][0]
concatenate (Concatenate)	(None, 30, 3)	0	input_layer[0][0], time2_vector[0][0]
transformer_encoder (TransformerEncoder)	(None, 30, 3)	47,890	concatenate[0][0], concatenate[0][0], concatenate[0][0]
transformer_encoder_1 (TransformerEncoder)	(None, 30, 3)	47,890	transformer_encoder[0][0], transformer_encoder[0][0], transformer_encoder[0][0]
transformer_encoder_2 (TransformerEncoder)	(None, 30, 3)	47,890	transformer_encoder_1[0][...], transformer_encoder_1[0][...], transformer_encoder_1[0][...]
global_average_pooling1d (GlobalAveragePooling1D)	(None, 30)	0	transformer_encoder_2[0][...]
dropout_6 (Dropout)	(None, 30)	0	global_average_pooling1d[...]
dense_111 (Dense)	(None, 64)	1,984	dropout_6[0][0]
dropout_7 (Dropout)	(None, 64)	0	dense_111[0][0]
dense_112 (Dense)	(None, 1)	65	dropout_7[0][0]

Mamba:

Layer (type)	Output Shape	Param #	Connected to
input_ids (InputLayer)	(None, 30, 1)	0	-
time2_vector (Time2Vector)	(None, 30, 2)	120	input_ids[0][0]
concatenate (Concatenate)	(None, 30, 3)	0	input_ids[0][0], time2_vector[0][0]
Residual_0 (ResidualBlock)	(None, 30, 3)	492	concatenate[0][0]
dropout (Dropout)	(None, 30, 3)	0	Residual_0[0][0]
Residual_1 (ResidualBlock)	(None, 30, 3)	492	dropout[0][0]
dropout_1 (Dropout)	(None, 30, 3)	0	Residual_1[0][0]
Residual_2 (ResidualBlock)	(None, 30, 3)	492	dropout_1[0][0]
dropout_2 (Dropout)	(None, 30, 3)	0	Residual_2[0][0]
Residual_3 (ResidualBlock)	(None, 30, 3)	492	dropout_2[0][0]
dropout_3 (Dropout)	(None, 30, 3)	0	Residual_3[0][0]
Residual_4 (ResidualBlock)	(None, 30, 3)	492	dropout_3[0][0]
dropout_4 (Dropout)	(None, 30, 3)	0	Residual_4[0][0]
global_average_pooling1d (GlobalAveragePooling1D)	(None, 30)	0	dropout_4[0][0]
dropout_5 (Dropout)	(None, 30)	0	global_average_pooling1d[...]
dense_20 (Dense)	(None, 64)	1,984	dropout_5[0][0]
dropout_6 (Dropout)	(None, 64)	0	dense_20[0][0]
dense_21 (Dense)	(None, 1)	65	dropout_6[0][0]

可以看到我是將 Transformer-based model 中的 TransformerEncoder 這個 block 直接替換成 ResidualBlock(selective SSM + skip connection)，並且在 ResidualBlock 之間設置 Dropout。因為我希望能在後面比較 Transformer-based 和 Mamba-based 的效能時可以有更值觀的比較結果，所以剩下的優化就是將 Mamba-based 的 ResidualBlock 層數設定為 5(經測試找到的最佳結果)、Dropout rate 設為 0.1、state size 設為 32，其餘模型的架構均相同，以此來更清楚的觀察 Mamba 架構針對參數數量、運行速度的改善效果。

任務三 - 回測結果及效能比較

1. 比較模型大小差異

Transformer-based:

Total params: 145,839 (569.68 KB)

Trainable params: 145,839 (569.68 KB)

Non-trainable params: 0 (0.00 B)

Mamba-based:

Total params: 4,629 (18.08 KB)

Trainable params: 4,629 (18.08 KB)

Non-trainable params: 0 (0.00 B)

結論：可以看出 Mamba-based 的參數數量是遠遠低於 Transformer-based 的。

2. 比較回測準確度

我從 2024/1/1 開始往後蒐集了 30 天的開市日價格資料，並選定 2024/2/23 作為待預測的日期

回測結果：

```
#####
TSMC 2024/2/23 High Price Prediction: 695.0
Transformer Predicted High Price: 617.2648
Mamba Predicted High Price: 627.3464
Transformer RMSE: 77.7352294921875
Mamba RMSE: 67.65362548828125
#####
TSMC 2024/2/23 Low Price Prediction: 685.0
Transformer Predicted Low Price: 610.638
Mamba Predicted Low Price: 612.9253
Transformer RMSE: 74.36199951171875
Mamba RMSE: 72.07470703125
#####
TSMC 2024/2/23 Open Price Prediction: 695.0
Transformer Predicted Open Price: 621.1307
Mamba Predicted Open Price: 629.1644
Transformer RMSE: 73.86932373046875
Mamba RMSE: 65.8355712890625
#####
TSMC 2024/2/23 Close Price Prediction: 692.0
Transformer Predicted Close Price: 607.20044
Mamba Predicted Close Price: 624.4637
Transformer RMSE: 84.799560546875
Mamba RMSE: 67.53631591796875
#####
```

結論：在每一種價格種類，Mamba-based 的 RMSE 都低於 Transformer-based。

3. 比較模型推論效率

最高價：

Transformer-based

1/1 ————— 6s 6s/step

Mamba-based

1/1 ————— 2s 2s/step

最低價：

Transformer-based

1/1 ————— 5s 5s/step

Mamba-based

1/1 ————— 2s 2s/step

開盤價：

Transformer-based

1/1 ————— 5s 5s/step

Mamba-based

1/1 ————— 2s 2s/step

收盤價：

Transformer-based

1/1 ————— 4s 4s/step

Mamba-based

1/1 ————— 2s 2s/step

結論：Mamba-based 對模型推論的效率有顯著增加